Chapitre 3
Introduction aux statistiques et présentation des données

Deux hommes vont à la chasse. Le premier tire à gauche de l'animal. Le deuxième vise un peu trop à droite. Ils s'exclament alors : « C'est bon, on l'a eu !».

Introduction

Dans son travail, un technicien en informatique peut être amené à faire des requêtes dans une base de données pour trouver certaines mesures statistiques (moyenne, écart type, etc.). Il est aussi possible que ce dernier, dans le but, par exemple, de valider l'efficacité du site web de son employeur, étudie la fréquentation des différentes sections de ce dernier et aura alors à recueillir des données et d'en faire l'analyse. Par ailleurs, afin de s'assurer de la qualité d'un logiciel, il n'est pas rare que des études statistiques soient faites. Dans le premier exemple, il est important d'être en mesure de comprendre ce que signifient les valeurs retournées par la requête. Dans les deux derniers exemples, le technicien recueillera des données, mais saura-t-il quoi en faire ?

L'objectif de cette partie du cours est de permettre aux futurs techniciens en informatique d'être en mesure de présenter les données obtenues lors d'un sondage sous forme de tableaux et de graphiques, puis de calculer et d'interpréter les valeurs statistiques les plus communes. Dans ce chapitre, nous verrons les notions de base en statistiques. Nous verrons ensuite comment présenter les données sous forme de tableaux et de graphiques. Le prochain chapitre portera sur le calcul et l'interprétation de mesures statistiques les plus courantes.

Le but du cours n'est pas de faire de vous un expert en analyse statistique, mais bien de vous outiller à comprendre et à calculer les différentes mesures statistiques les plus utilisées. Afin d'y arriver, quelques définitions de base sont nécessaires.

Un peu de vocabulaire

Voici quelques définitions importantes à établir avant de poursuivre.

Définition

Une **population** est l'ensemble des entités, appelées *individus* (personnes, objets, faits) sur lesquels porte l'étude statistique.
Taille :
N =nombre d'individus appartenant à la population.
Étude statistique :
Le recensement : étude qui porte sur l'ensemble des unités statistiques de la population.
Désavantages : long, dispendieux, parfois impossible à faire
Organismes : Statistique Canada, BSQ

Définition

Une unité statistique est chacun des éléments de la population.

Définition

Un **échantillon** est un sous-ensemble de la population : on choisit une partie des N unités statistiques formant la population.

Taille :
n unités statistiques choisies parmi les N unités statistiques formant la population.
n = nombre d'individus appartenant à l'échantillon.
Remarque. Les notations n et N ont des significations différentes. Une attention particulière doit donc être portée aux lettres minuscules et majuscules.

Caractéristiques :

— Représentatif : Toutes les caractéristiques de la population doivent se retrouver à l'intérieur de l'échantillon.

— Aléatoire : Chaque individu de la population a une chance égale d'appartenir à l'échantillon.

Étude statistique :
Le sondage (ou échantillonnage) : étude qui porte sur un échantillon de la population.
Avantages : moins long et moins dispendieux
Organismes : Firmes de sondage ex. Léger & Léger

Que l'étude porte sur une population ou sur un échantillon de cette dernière aura un impact sur la façon dont sont calculées certaines mesures statistiques que nous verrons dans le prochain chapitre. Il faut donc bien être en mesure de distinguer un recensement d'un sondage.

Exemple
Si notre étude porte sur l'ensemble des lettres de l'alphabet, la population serait l'ensemble des 26 lettres. On aura alors que la taille de la population est $N = 26$. Si l'échantillon considéré est constitué des lettres J, O et Y, on aura alors un échantillon de taille $n = 3$. N'importe quelle lettre de cet ensemble, par exemple le W, est appelée une *unité statistique*.

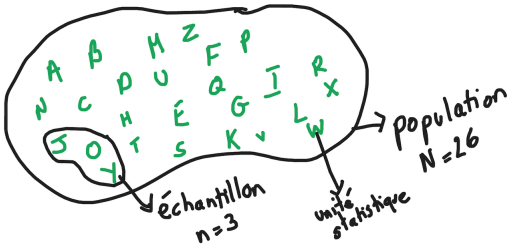

Exercices

1. Une enseignante sélectionne au hasard 6 questions d'un examen en comportant 20 afin de valider les démarches effectuées par les étudiants du cours *Nombres et statistiques*.
   (a) Quelle est la population ?
   (b) Que vaut N ?
   (c) Quel est l'échantillon ?
   (d) Que vaut n ?

2. Une enseignante effectue un sondage afin de recueillir les commentaires de ses 30 étudiants au sujet du cours *Nombres et statistiques*. Le tiers de ses étudiants ont répondu.
   (a) Quelle est la population ?
   (b) Que vaut N ?
   (c) Quel est l'échantillon ?
   (d) Que vaut n ?

3. Dans le but de faire un contrôle qualité d'un modèle de chandail qu'elle fabrique, une compagnie effectue un échantillonnage de 100 chandails de ce modèle.
   (a) Quelle est la population ?
   (b) Que vaut N ?
   (c) Quel est l'échantillon ?
   (d) Que vaut n ?

Types de variables

Définition

Une **variable** est la caractéristique étudiée dans la population, que l'étude statistique soit un sondage ou un recensement.

Exercices

Pour chacun des exemples suivants :

1. identifiez s'il s'agit d'un échantillon ou d'une population ;
2. identifiez la population ;
3. identifiez la variable étudiée.

1. **Une enseignante effectue un sondage auprès de ses étudiants afin de connaître le nombre d'heures d'études en mathématiques que ces derniers effectuent à chaque semaine.**
   (a) un échantillon ou une population :
   (b) population :
   (c) variable étudiée :

2. **Une compagnie de sondage appelle 100 adultes québécois afin de connaître pour quel parti ils prévoient voter lors des prochaines élections fédérales.**
   Il s'agit d'un échantillon, puisque seule une partie de tous les adultes québécois a été appelée.
   (a) un échantillon ou une population :
   (b) population :
   (c) variable étudiée :

3. **On veut évaluer la moyenne des données de chacun des disques durs d'un serveur afin de s'assurer que les disques durs sont utilisés de façon équitable.**

   (a) un échantillon ou une population :
   (b) population :
   (c) variable étudiée :

Dans les exemples précédents, différents types de variables ont été utilisées. Selon son type, la présentation des données et le calcul des mesures statistiques seront différentes. Voyons alors quels sont les types de variables possibles.

Définition

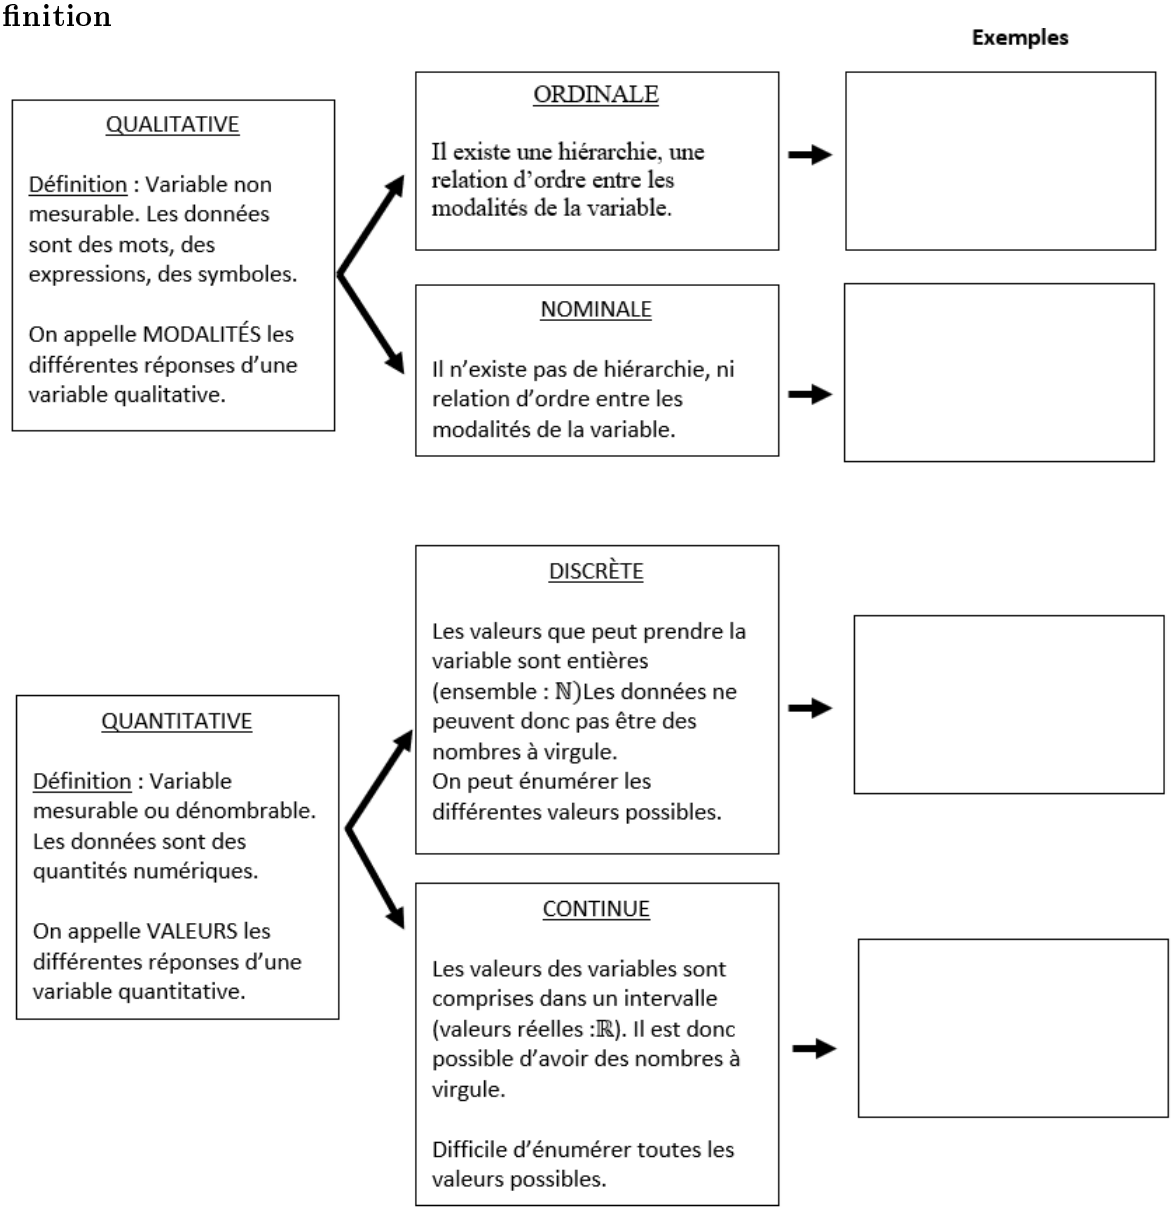

Exercices

Pour chacune des variables suivantes, identifiez si elle est qualitative ou quantitative. Si elle est qualitative, déterminez si elle est nominale ou ordinale. Si elle est quantitative, déterminez si elle est discrète ou continue.

1. Le poids d'une personne :

2. L'état civil :

3. La durée d'une nuit de sommeil :

4. Le sexe d'une personne :

5. L'âge d'une personne arrondi à un entier :

6. Le temps pour aller de St-Jérôme à Montréal :

7. La note à un examen :

8. La couleur des yeux :

9. Le degré de motivation à participer au cours :

Présentation des données sous forme de tableaux

Lorsque l'on fait une étude statistique, les valeurs ou modalités obtenues pour la variable forment ce qu'on appelle une **série statistique**. Par exemple, si on effectue un recensement pour déterminer l'âge arrondi des 15 étudiants d'un groupe, on pourrait obtenir la série statistique suivante :

19 38 52 20 22 20 21 23 18 19 29 34 19 22 19

Il est difficile d'avoir un portrait clair des données obtenues en les présentant de cette façon. Il peut alors être judicieux de les présenter sous forme de tableau ou de graphique. Dans cette section, nous présenterons les différentes normes à respecter pour présenter une série statistique sous forme de tableaux. Dans la prochaine section, on se penchera sur les différentes représentations sous forme de graphiques.

Définition

Le **tableau de distribution de fréquences** permet de présenter de façon synthétique les données brutes et de constater la répartition des individus étudiés selon les différentes modalités, valeurs ou classes de valeurs.

Donner un titre au tableau de distribution

— Forme admissible pour **une population** : « Répartition (ou distribution) **des** (unités statistiques) selon (nom de la variable) » (ou l'équivalent).

— Forme admissible pour **un échantillon** : « Répartition (ou distribution) **de** (unités statistiques) selon (nom de la variable) » (ou l'équivalent).

Exemple
Si on interroge les 15 étudiants d'un groupe, on pourrait obtenir le tableau de dsitribution de fréquences suivant :

Répartition des 15 étudiants du groupe selon leur âge

Âge (années) x_i	Nombre d'étudiants n_i	Pourcentage d'étudiants (%) f_i
18	1	6.7
19	4	26.7
20	2	13.3
21	1	6.7
22	2	13.3
23	1	6.7
29	1	6.7
34	1	6.7
38	1	6.7
52	1	6.7
Total	15	100.0

Lors de la présentation d'une série statistique sous forme de tableau, certaines normes doivent être respectées et sont précisées dans ce qui suit.
Caractéristiques du tableau de distribution

- La **première colonne** a pour titre **le nom de la variable**. On inscrit dans la première colonne les modalités, valeurs ou classe de valeurs que prend la variable. Si la variable est continue, on utilisera des classes.

- La **deuxième colonne** a pour titre **Nombre (d'unités statistiques).** On inscrit l'effectif ou la fréquence absolue (n_i) qui représente le nombre de fois qu'une variable prend une certaine modalité ou valeur.
- La **troisième colonne** a pour titre le **Pourcentage (d'unités statistiques)**. On inscrit la fréquence relative (f_i). C'est le rapport (en %) entre la fréquence absolue et la taille de l'échantillon (ou de la population).

$$f_i = \frac{n_i}{n} = \frac{\text{fréquence absolue}}{\text{taille de l'échantillon}} \text{ ou } f_i = \frac{n_i}{N} = \frac{\text{fréquence absolue}}{\text{taille de la population}}.$$

- La dernière ligne du tableau représente le total du nombre et du pourcentage d'unités statistiques.
- Par convention, les pourcentages sont arrondis à une décimale.
- Le total des pourcentages est toujours arrondi à 100.0%.

Exercices

1. On a choisi aléatoirement 110 des 5000 étudiants d'un Cégep et à la question *Combien de fois par semaine avez-vous un cours à 8h le matin ?*, on a obtenu les résultats suivants :

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
1	1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1	1
2	2	2	2	2	2	2	2	2	2
2	2	2	2	2	2	2	2	2	2
2	2	2	2	2	2	2	2	2	2
2	2	2	2	2	2	2	2	2	2
3	3	3	3	3	3	3	3	3	3
4	4	4	4	4	5	5	5	5	5

Complétez le tableau de distribution de fréquences suivant représente cette série statistique.

Répartition de

Nombre de cours en présentiel	Nombre d'étudiants	Pourcentage d'étudiants (%)
0		
1		
2		
3		
4		
5		
Total		

2. On a interrogé 15 étudiants afin de connaître leur animal préféré. On a obtenu les réponses suivantes :

chat	chien	canari	tortue	lapin
chien	rat	chat	chat	ours
canard	rat	chat	chat	chien

Construisez le tableau de distribution de fréquences en prenant soin de lui donner un titre approprié.

Remarquez que dans l'exercice précédent, bien que la somme des fréquences relatives arrondies (%) ne soit pas exactement de 100.0, on arrondit la somme à 100.0 puisque l'on sait que la valeur de 100.1 obtenue est dû au fait que chacune des fréquences relatives a été arrondie.

Formation de classes

Les trois exemples présentés concernaient des variables quantitatives discrètes avec peu de valeurs ou une variable qualitative. Dans le cas où la variable étudiée est quantitative continue, il est impossible de faire un tableau avec une ligne par valeur possible, puisque les valeurs possibles ne peuvent pas être toutes énumérées. Par ailleurs, avec une variable quantitative discrète avec beaucoup de valeurs possibles (disons **plus de 12**), il devient moins facile de comprendre l'information dans un tableau ayant un grand nombre de lignes.

Ainsi, lorsque la variable est quantitative continue ou quantitative discrète avec un nombre de valeurs **plus grand que 12**, on va regrouper les valeurs possibles en **classes**. L'encadré suivant explique les étapes à suivre pour former les classes.

Étapes à suivre pour former les classes (pour variables quantitatives continues ou quantitatives discrètes à plus de 12 valeurs) :

1. Trouver le nombre approximatif de classes selon la table de Sturges et la taille de l'échantillon n (ou population N s'il s'agit d'un recensement) :

Table de Sturges

Nombre de données (n)	Nombre approximatif de classes
Moins de 23	5
De 23 à 45	6
De 46 à 90	7
De 91 à 180	8
De 181 à 361	9
De 362 à 723	10
De 724 à 1447	11
De 1448 à 2895	12

2. Trouver l'**étendue** :

   ÉTENDUE = Valeur maximale - Valeur minimale de la série statistique.

3. Calculer l'**amplitude** de chaque classe :

$$\text{AMPLITUDE} = \frac{\text{Étendue}}{\text{Nombre approximatif de classes}}.$$

4. L'amplitude choisie sera idéalement un nombre pair ou un multiple de 5 (ou de 0.5).

5. Choisir la limite inférieure de la première classe pour avoir un tableau agréable à lire. Elle doit être inférieure à la plus petite valeur de la série statistique.

6. Construire chaque classe à partir de ces informations.

Remarque. Lors de la construction de classes, on doit s'assurer que toutes les valeurs fassent partie d'une et une seule classe.

Exemple

On a choisi aléatoirement 60 des 5000 étudiants d'un Cégep qui ont répondu à la question *Combien de temps (en heures, arrondies) jouez-vous au jeux vidéos par semaine ?* On obtient la série statistique ordonnée suivante :

0	0	0	0	0	0	0	0	0	1
1	1	2	2	3	4	5	5	5	10
10	10	10	10	12	12	12	12	15	16
16	20	20	20	20	20	20	20	20	21
22	22	23	23	24	25	27	29	30	32
35	35	38	39	40	40	40	40	50	60

Construire le tableau de distribution des fréquences en formant des classes.

La variable est le temps (en heures, arrondies) hebdomadaire passé à jouer à des jeux vidéos. Il s'agit d'une variable quantitative discrète avec plus de 12 différentes valeurs. Il faut donc créer des classes. Suivons les étapes :

1. La taille de l'échantillon est $n = 60$. Selon la table de Sturges, puisque $46 \leq 60 \leq 90$, le nombre approximatif de classes est de 7.

2. Étendue $= 60 - 0 = 60$.

3. Amplitude $= \dfrac{\text{Étendue}}{\text{Nombre approximatif de classes}} = \dfrac{60}{7} \approx 8.6$.

4. En arrondissant, on obtient une amplitude de 9. On choisit de prendre 10, qui fera des classes plus *rondes*.

5. On fixe la limite inférieure de la première classe à 0.

Complétez le tableau de distribution de fréquences.

$[0; 10[$		
$[10; 20[$		
$[20; 30[$		
$[30; 40[$		
$[40; 50[$		
$[50; 60[$		
$[60; 70[$		
Total	60	100.0

Présentation des données sous forme d'un graphique

Lorsque l'on fait un sondage ou un recensement, on se retrouve avec une série de données que l'on peut organiser et présenter sous forme d'un tableau de distribution de fréquences comme dans la section précédente. On peut aussi représenter graphiquement la série de données. Cela nous permet en un seul regard de voir si une certaine tendance se dessine. Pour chacun des quatre types de variables, il existe des types de graphiques appropriés à utiliser. Mais peu importe le type de variable et de graphiques, les conventions suivantes doivent être respectées.

Normes de présentation communes des graphiques

1. Chaque graphique doit avoir un titre qui indique la population ou l'échantillon concerné et la variable étudiée de la façon suivante : *Distribution (ou répartition) de (la population ou de l'échantillon) selon (la variable étudiée)*. Il s'agit du même titre que celui du tableau de distribution de fréquences.
2. Les modalités, valeurs ou classes doivent être bien définies et apparaître sur les axes.
3. Les axes doivent avoir un titres et les unités de mesures doivent y être précisées.
4. Les axes doivent être orientés (avec une flèche) et dotés d'une graduation proportionnelle lorsqu'ils représentent une fréquence ou une variable quantitative.
5. À moins d'indication contraire, l'axe des fréquences peut utiliser les fréquences absolues ou les fréquences relatives (les pourcentages).
6. Afin de faciliter la lecture, une brisure d'axe peut être utilisée.

Dans ce qui suit, on présente les types de graphiques à utiliser selon le type de la variable étudiée.

Variables qualitatives nominales

Pour les variables qualitatives nominales, deux types de graphiques sont possibles :

— Le diagramme **circulaire** : pour les variables **qualitatives nominales** à 7 modalités ou moins ;

— Le diagramme à **rectangles horizontaux**.

Diagramme circulaire

Le **diagramme circulaire (ou à secteurs)** est utilisé pour représenter des variables qualitatives nominales. Il a la forme d'un cercle qu'on divise en autant de secteurs qu'il y a de modalités pour la variable. L'angle de chacun des secteurs est proportionnel à la fréquence relative de la modalité qu'il représente. On obtient l'angle du secteur à l'aide de la formule suivante :

$$\text{Angle du secteur} = \text{fréquence relative de la modalité} \times 360°.$$

On identifie chacun des secteurs par une légende ou en inscrivant la modalité directement sur le graphique, à côté des secteurs.

Diagramme à rectangles horizontaux

Si la variable est qualitative nominale, on peut aussi utiliser un diagramme à rectangles horizontaux.

Le diagramme à rectangles horizontaux est composé de rectangles disjoints (qui ne se touchent pas), d'égale largeur et de hauteur (ou longueur) proportionnelle à la fréquence (relative ou absolue) de la modalité qu'ils représentent. L'axe des fréquences doit être orienté.

Exemple

À partir du tableau de distribution de fréquences suivant, on obtient les diagrammes suivants.

Répartition des 15 étudiants selon le fait d'avoir déjà suivi un cours sur Teams ou non

Expérience de cours sur Teams	Nombre d'étudiants	% d'étudiants
Oui	9	60.0
Non	6	40.0
TOTAL	15	100.0

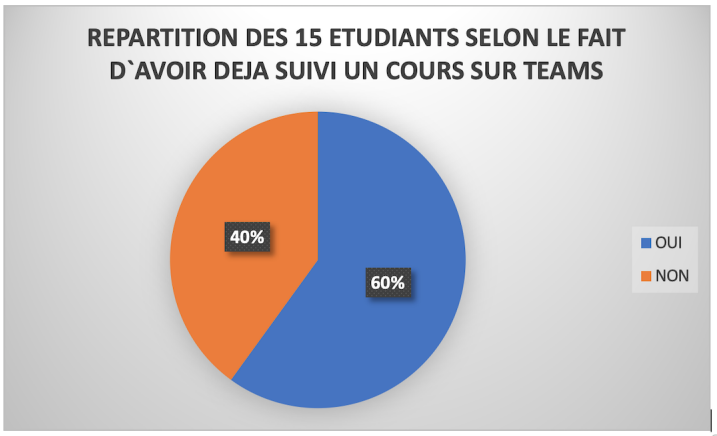

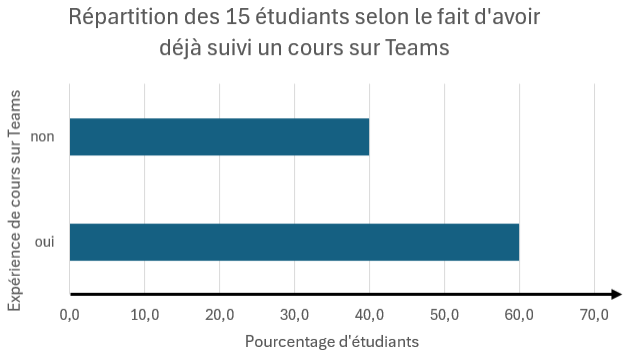

Variables qualitatives ordinales

Pour les variables qualitatives ordinales, il faut utiliser le diagramme à **rectangles verticaux**.

Diagramme à rectangles horizontaux

Le diagramme à rectangles verticaux est composé de rectangles disjoints (qui ne se touchent pas), d'égale largeur et de hauteur (ou longueur) proportionnelle à la fréquence (relative ou absolue) de la modalité qu'ils représentent. L'axe des fréquences doit être orienté et kes modalités sont ordonnées.

Considérons le tableau de distribution de fréquences suivant.

Répartition des 14 étudiants selon leur motivation face au cours de Probabilités et statistiques

Degré de motivation	**Nombre d'étudiants**	**% d'étudiants**
Un peu motivé.e.	4	28.6
Très motivé.e, je l'attendais depuis la session 1 !	4	28.6
J'ai pas trop le choix, c'est la dernière fois qu'il se donne.	4	28.6
Motivé !	1	7.1
À péter des règles, des calculatrices et réussir mon cours	1	7.1
TOTAL	14	100.0

Il s'agit d'une variable qualitative ordinale. On va alors ordonner les modalités. On obtient le diagramme à rectangles verticaux suivant.

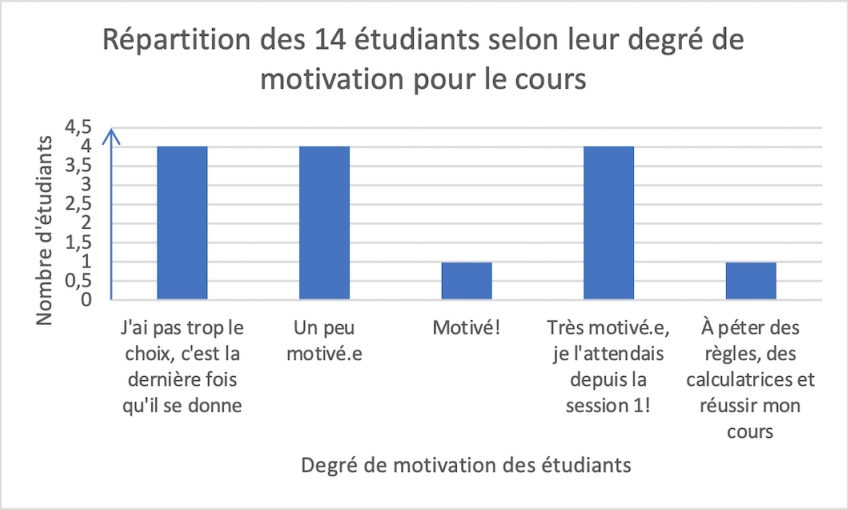

Variables quantitatives

Pour les variables quantitatives, il y a 4 principaux types de diagrammes possibles :

- le diagramme en bâtons : pour une **variable quantitative discrète** avec 12 valeurs ou moins.
- l'histogramme : pour une **variable quantitative continue** ou pour une variable quantitative discrète avec plus de 12 valeurs possibles.
- le polygone de fréquences : pour les mêmes types de variables qu'un histogramme.
- l'ogive (ou courbe des fréquences cumulées) : pour les mêmes types de variables qu'un histogramme.

Remarque. Prenez note que ce soit pour un tableau de distribution de fréquences ou pour un diagramme, une variable quantitative discrète à plus de 12 valeurs est toujours traitée comme s'il s'agissait d'une variable quantitative continue.

Diagramme en bâtons

Voici les règles de construction du diagrammes en bâtons :

- Ce graphique est obtenu en traçant des traits verticaux, c'est-à-dire parallèles à l'axe des y. Ces lignes doivent être plutôt minces (et non des rectangles) de hauteur proportionnelle à la fréquence (absolue ou relative) de chacune des valeurs de la variable.
- La distance entre chacun des bâtons doit être la même.
- Si «0» est une valeur possible de la variable, il peut y avoir un déphasage à droite.

Exemple

Considérons le tableau de distribution de fréquences suivant.

Répartition des 15 étudiants selon le nombre de cours auxquels ils sont inscrits cette session

Nombre de cours	**Nombre d'étudiants**	**% d'étudiants**
3	1	6.7
5	9	60.0
6	4	26.7
7	1	6.7
TOTAL	15	100.0

Le diagramme en bâtons qui suit représente cette distribution. On a choisit d'utiliser les fréquences relatives (%), mais on aurait très bien pu utiliser les fréquences absolues.

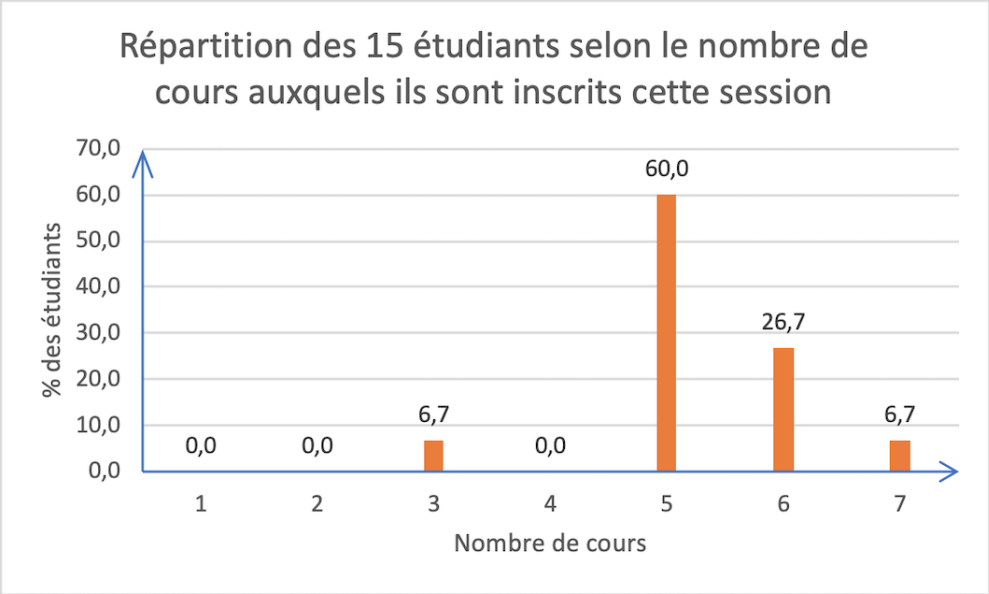

Remarquez que dans ce graphique, une coupure d'axe aurait pu permettre d'éviter de mettre les valeurs 1 et 2 sur l'axe horizontal. Remarquez aussi qu'avec Excel, on met les rectangles aussi minces que possible. Idéalement, les minces rectangles auraient été des lignes.

Histogramme

Si la variable est quantitative discrète avec plus de 12 valeurs possibles ou si elle est quantitative continue, on va plutôt utiliser un **histogramme** pour représenter graphiquement les données.

- Les données doivent avoir été préalablement regroupées en classes.
- L'histogramme est caractérisé par ses rectangles qui se touchent, ce qui permet d'illustrer la continuité des variables étudiées.
- Les rectangles sont collés et de hauteur proportionnelle à la fréquence, de largeur correspondant à l'amplitude de la classe.
- Si on a une classe ouverte : on ferme la classe en lui donnant la même amplitude que les autres classes.

Exemple
Voici le tableau qui représente les résultats obtenus lorsqu'on a questionné des étudiants afin de connaître leur nombre préféré parmi les entiers compris entre 1 et 30.

Répartition des 24 étudiants selon leur nombre préféré entre 1 et 30

Nombre préféré	Nombre d'étudiants	% d'étudiants
$[0, 5[$	3	12.5
$[5, 10[$	7	29.2
$[10, 15[$	2	8.3
$[15, 20[$	3	12.5
$[20, 25[$	5	20.8
$[25, 30[$	3	12.5
$[30, 35[$	1	4.2
TOTAL	24	100.0

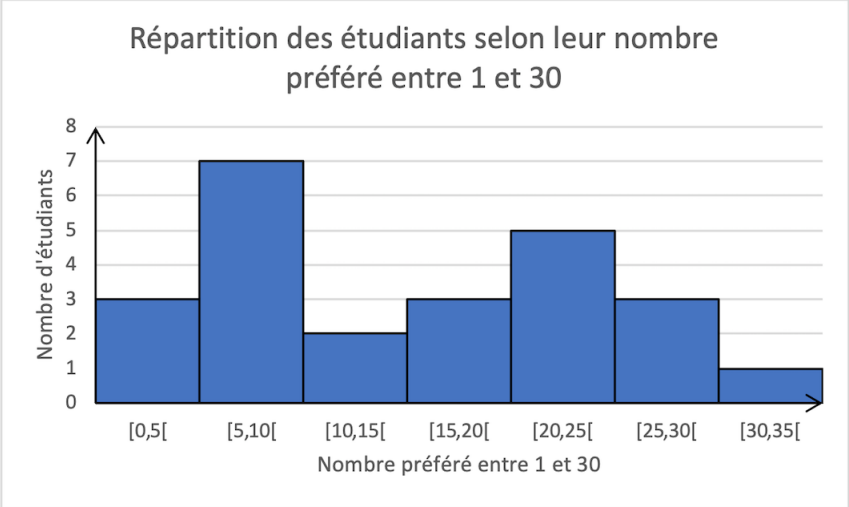

L'exemple suivant illustre un tableau de distribution de fréquences avec une classe ouverte.

Exemple
Considérons le tableau de distribution de fréquences suivant.

Répartition des 50 villes selon la quantité de pluie tombée le 9 septembre 2020

Quantité de pluie en mm	Nombre de villes	% de villes
$[0, 5[$	31	62.0
$[5, 10[$	12	24.0
$[10, 15[$	6	12.0
15 et plus	1	2.0
TOTAL	50	100.0

La dernière ligne du tableau représente une classe ouverte. Pour construire l'histogramme approprié, on imagine que la dernière classe est $[15, 20[$. On obtiendrait alors l'histogramme suivant :

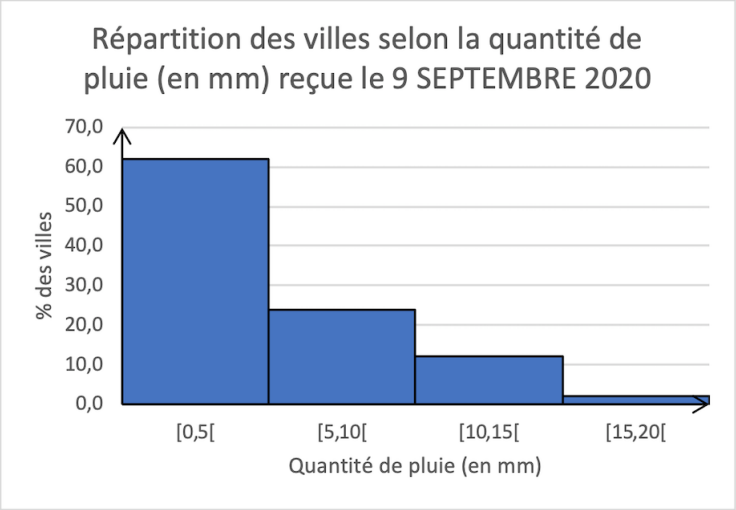

Polygone de fréquences

À partir de l'histogramme, il est possible de construire un **polygone de fréquences** de la façon suivante :

1. On joint par un segment de droite les points milieux des sommets de tous les rectangles de l'histogramme.
2. On ferme la figure en ajoutant au début et à la fin de l'histogramme, une classe de fréquence nulle.

À partir du premier exemple de l'histogramme, on obtient le polygone de fréquences suivant.

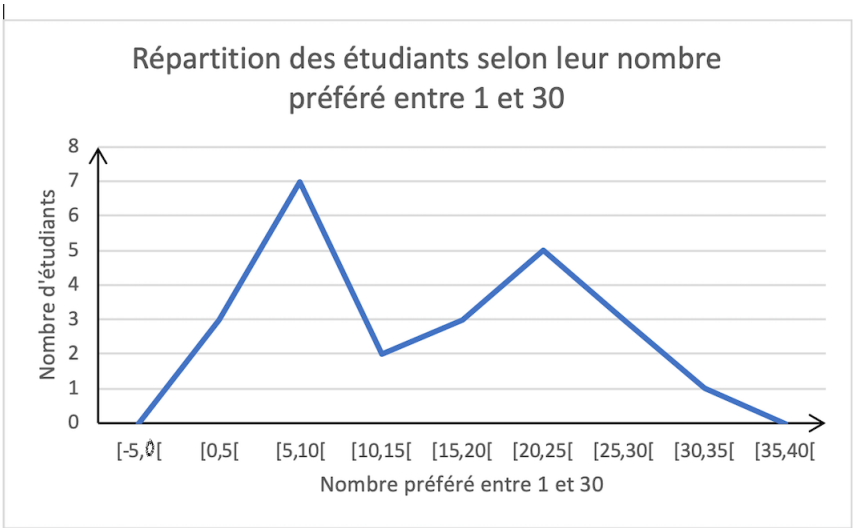

Remarquons que dans le polygone de fréquences ci-dessus, l'intervalle $[-5, 0[$ n'est pas placé là où on s'y attendrait, c'est-à-dire avec le -5 du côté négatif de l'axe horizontal. Ceci est dû à Excel qui n'est pas très flexible pour la construction de diagrammes.

Il est aussi possible de graduer l'axe horizontal en ne mettant que le point milieu de chacun des intervalles. On obtient le polygone de fréquences suivant :

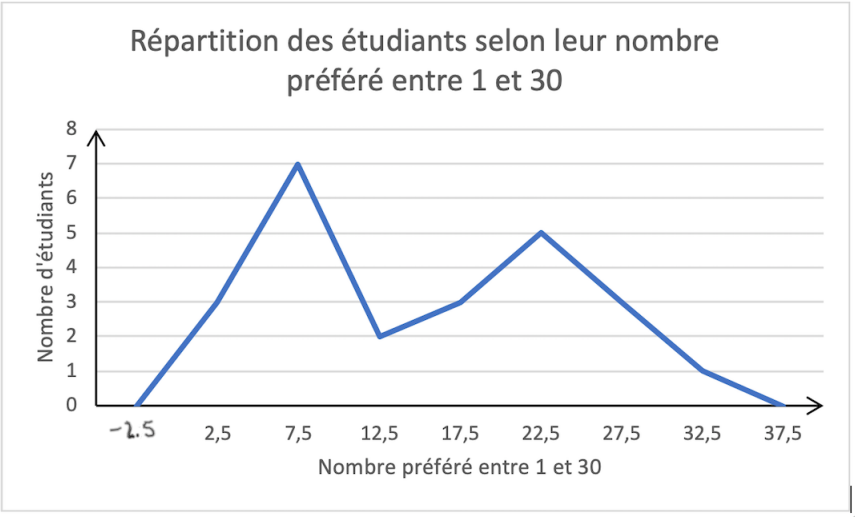

Dans ce polygone de fréquences, on peut aussi remarquer que le 0 sur l'axe horizontal n'est pas placé vis-à-vis de l'axe horizontal comme il le devrait (gracieuseté : rigidité d'Excel).

Ogive

Le dernier type de graphique que nous présentons est aussi utilisé pour les variables quantitatives continues ou discrètes avec plus de 12 valeurs. Pour le construire, on doit ajouter une quatrième colonne au tableau de distribution de fréquences afin de représenter les fréquences relatives cumulées.

Reprenons le deuxième tableau de distribution de fréquences de l'histogramme et ajoutons-lui une colonne qui représente les fréquences relatives cumulées.

Répartition des 50 villes selon la quantité de pluie tombée le 9 septembre 2020

Quantité de pluie en mm	**Nombre de villes**	**% de villes**	% cumulés de villes
$[0, 5[$	31	62.0	62.0
$[5, 10[$	12	24.0	**86.0**
$[10, 15[$	6	12.0	98.0
15 et plus	1	2.0	100.0
TOTAL	50	100.0	

La dernière colonne indique, pour chaque valeur ou pour chaque classe, le pourcentage des valeurs qui lui sont inférieures. Dans l'exemple précédent, la valeur **86.0** indique que 86.0% des villes ont reçu moins de 10mm de pluie le 9 septembre 2020.

À partir de cette colonne, on peut alors construire l'ogive suivante :

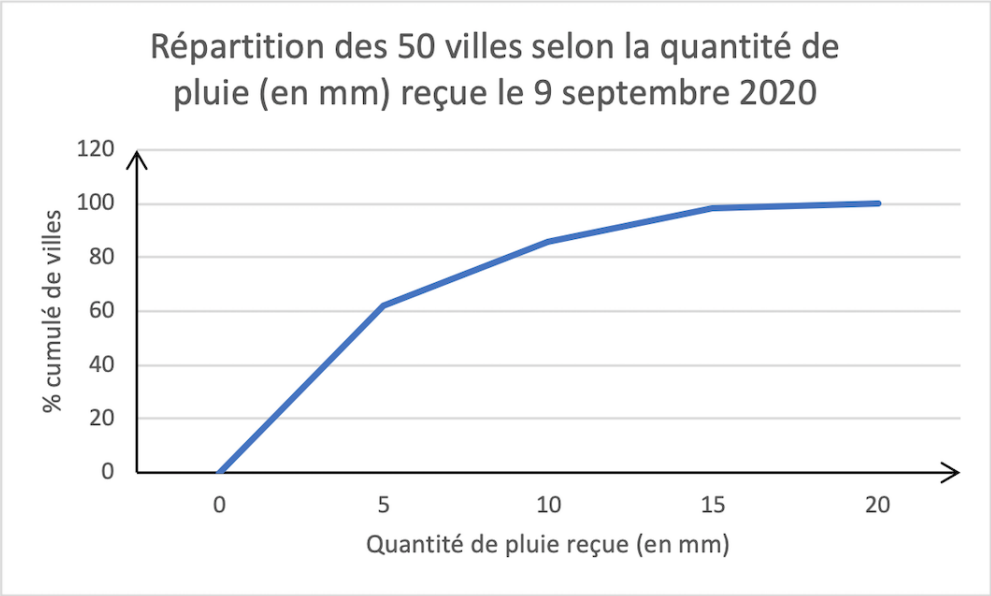

En résumé

Terminologie

Lors d'une étude statistique :

- **Unités statistique** : un élément de la population étudiée.
- Si toute la population est étudiée : **Recensement**.
  Il y a alors : N unités statistiques
- Si une partie de la population est étudiée : **Sondage** ou **échantillonage**.
  Il y a alors : n unités statistiques

Les types de variables :

- **Qualitative** : la variable n'est pas mesurable. Les données (**modalités**) sont des mots, des expressions, des symboles.
  - **Nominale :** impossible d'ordonner les modalités
  - **Ordinale :** possible d'ordonner les modalités
- **Quantitative** : la variable est mesurable. Les données (**valeurs**) sont des quantités numériques.
  - **Discrète :** possible d'énumérer toutes les valeurs possibles
  - **Continue :** impossible d'énumérer toutes les valeurs possibles

  Le temps et le poids sont pratiquement toujours des variables quantitatives continues.

Présentation des données sous forme de graphiques

Le tableau qui suit résume les graphiques appropriés selon le type de la variable étudiée.

Nom du diagramme	**Type de variable**
Diagramme circulaire	Qualitative nominale à 7 modalités ou moins
Diagramme à rectangles horizontaux	Qualitative nominale
Diagramme à rectangles verticaux	Qualitative ordinale
Diagramme en bâtons	Quantitative discrète avec 12 valeurs ou moins
Histogramme, polygone de fréquences, ogive	Quantitative discrète avec plus de 12 valeurs ou quantitative continue

Construction de classes lorsque nécessaire

Étapes à suivre pour former les classes (pour variables quantitatives continues ou quantitatives discrètes à plus de 12 valeurs :

1. Trouver le nombre approximatif de classes selon la table de Sturges et la taille de l'échantillon n (ou population N s'il s'agit d'un recensement) :

Table de Sturges

Nombre de données (n)	Nombre approximatif de classes
Moins de 23	5
De 23 à 45	6
De 46 à 90	7
De 91 à 180	8
De 181 à 361	9
De 362 à 723	10
De 724 à 1447	11
De 1448 à 2895	12

2. Trouver l'**étendue** :

   ÉTENDUE = Valeur maximale - Valeur minimale de la série statistique.

3. Calculer l'**amplitude** de chaque classe :

$$\text{AMPLITUDE} = \frac{\text{Étendue}}{\text{Nombre approximatif de classes}}.$$

4. L'amplitude choisie sera idéalement un nombre pair ou un multiple de 5 (ou de 0.5).

5. Choisir la limite inférieure de la première classe pour avoir un tableau agréable à lire. Elle doit être inférieure à la plus petite valeur de la série statistique.

6. Construire chaque classe à partir de ces informations.

Exercices

1. Pour chaque mise en situation, identifiez :
   - s'il s'agit d'un recensement ou d'un sondage ;
   - la population étudiée
   - la taille de la population et/ou de l'échantillon ;
   - la variable ;
   - le type de variable.

   (a) On a interrogé 60 adolescents de Saint-Jérôme pour connaître le nombre de cigarettes qu'ils fument à chaque semaine.

   (b) On a interrogé 15 étudiants d'un groupe afin de savoir s'ils ont des animaux à la maison.

   (c) On a interrogé les 15 étudiants d'un groupe afin de savoir combien ils ont des animaux à la maison.

   (d) On a observé le nombre de visites sur un site web pour 12 jours du mois de juin 2020.

   (e) On a pris en note la quantité de pluie tombée sur 10 villes canadiennes le 15 août dernier.

   (f) On a interrogé des québécois afin de connaître leur saison préféré.

   (g) On a interrogé les étudiants habitant les résidences afin de connaître leur degré de satisfaction par rapport à la salubrité des lieux.

   (h) On a interrogé des étudiants habitant les résidences afin de connaître le nombre d'heures de sommeil de la dernière nuit.

   (i) On a pris en note le nombre de cas de COVID-19 détecté parmi les patients de 5 hôpitaux québécois pour le 5 août 2020.

   (j) On a observé le nombre d'oeufs pondus pour chacune des 10 poules d'un poulailler pendant l'hiver 2019-2020.

2. Une enseignante effectue un sondage auprès de ses étudiants. Pour chacune des questions,
   - déterminez la variable étudiée
   - déterminez le type de variable
   - présentez la série de données sous forme d'un tableau de distribution de fréquences en respectant les conventions.

   (a) À la question *Quel est ton degré de motivation face au cours de Probabilités et statistiques ?*, les réponses obtenues sont :

   Un peu motivé.e.
   Un peu motivé.e.
   Très motivé.e, je l'attendais depuis la session 1 !
   J'ai pas trop le choix, c'est la dernière fois qu'il se donne.
   J'ai pas trop le choix, c'est la dernière fois qu'il se donne.
   Très motivé.e, je l'attendais depuis la session 1 !
   Motivé !
   J'ai pas trop le choix, c'est la dernière fois qu'il se donne.
   Un peu motivé.e.
   Très motivé.e, je l'attendais depuis la session 1 !
   À péter des règles, des calculatrices et réussir mon cours
   Très motivé.e, je l'attendais depuis la session 1 !
   J'ai pas trop le choix, c'est la dernière fois qu'il se donne.
   Un peu motivé.e.

   (b) À la question *À combien de cours es-tu inscrit cette session-ci ?*, les réponses obtenues sont :

6	5	6	5
5	5	5	5
6	5	5	7
3	5	6	

   (c) À la question *As-tu déjà suivi un cours sur Teams ?*, les réponses obtenues sont :

Non	Oui	Oui	Oui
Oui	Oui	Oui	Oui
Non	Non	Non	Oui
Non	Oui	Non	

   (d) À la question *Combien d'animaux as-tu à la maison ?*, les réponses obtenues sont :

1	2	4	1
1	1	1	1
1	1	2	1
1	1	3	

3. Une enseignante effectue un sondage auprès de ses étudiants. Pour chacune des questions,

   — déterminez la variable étudiée

   — déterminez le type de variable

   — formez des classes qui respectent les conventions.

   (a) À la question *En km, à quelle distance du Cégep habites-tu ?*, les réponses obtenues sont :

3.6	11	45	6
8	16	22	15
30	1.5	16	3
2	50		

   (b) À la question *Combien d'heures par semaine joues-tu aux jeux vidéos ?*, les réponses obtenues sont :

40	7.5	1	2.5
0	10	10	15
20	1	5	

   (c) À la question *Quel âge as-tu ?*, les réponses obtenues sont :

42	25	20	20
20	25	27	19
20	29	32	23
20	20	23	20
28	25	20	22

   (d) À la question *Quel est ton nombre préféré entre 1 et 30*, les réponses obtenues sont :

7	7	13	20
22	21	15	18
5	3	7	13
27	21	23	25
18	30	9	6
1	29	7	4

4. Pour chacun des contextes suivants,
   — identifiez s'il s'agit d'un recensement ou d'un sondage
   — la population
   — l'unité statistique
   — la variable étudiée
   — le type de variable
   — le(s) nom(s) des diagramme(s) qui pourrai(en)t être utilisé(s) pour représenter la série de données obtenue.

   (a) On a interrogé au hasard 1000 étudiants du Cégep de Saint-Jérôme et on leur a demandé dans quel programme ils étaient inscrits.

   (b) On a relevé le nombre de décès au Québec au mois d'août 2020 et on a pris en note la cause du décès.

   (c) Une entreprise souhaite étudier l'absentéisme chez ses employés pendant la saison d'hiver. Pour se faire, elle relève le nombre de jours d'absences de 50 de ses employés lors de l'hiver 2019-2020.

   (d) Une entreprise souhaite étudier l'absentéisme chez ses employés pendant la saison d'hiver. Pour se faire, elle relève le nombre d'heures d'absences pour chacun de ses employés lors de l'hiver 2019-2020.

   (e) Le ministère des transports étudie les données sur les accidents qui ont eu lieu en 2019 dans un tronçon de route réputé être dangereux. Elle relève la gravité des accidents, allant de léger à mortel, de tous les accidents qui y ont eu lieu en 2019.

   (f) Un fabriquant de jeux vidéo souhaite connaître les habitudes de jeux de ses clients et interroge un échantillon de 50 joueurs afin de connaître le temps hebdomadaire que ces derniers passent à jouer.

5. Pour chacun des tableaux de distribution de fréquences, dites le diagramme approprié pour représenter les données.

   (a) On a interrogé au hasard 1000 étudiants du Cégep de Saint-Jérôme et on leur a demandé dans quel programme ils étaient inscrits. On obtient le tableau de distribution de fréquences suivant :

Répartition des 1000 étudiants du Cégep de Saint-Jérôme selon leur programme d'études

Programme d'études	Nombre d'étudiants	% d'étudiants
Techniques de l'informatique	180	18.0
Sciences de la nature	150	15. 0
Sciences informatiques et mathématiques	90	90.0
Génie mécanique	140	14.0
Techniques administratives	220	22.0
Sciences humaines	220	22.0
TOTAL	1000	100.0

(b) On a relevé tous les décès au Québec au mois d'août 2020 et on a pris en note la cause du décès. On obtient le tableau de distribution de fréquences suivant :

Répartition des décès survenus au Québec en août 2020 selon leur cause :

Cause du décès	% de décès
Tumeurs	33.0
Maladies du coeur	25.0
Maladies cérébrovasculaires	20.0
Accidents	15.0
Maladies chroniques des voies respiratoires inférieures	5.0
Grippe et pneumopathie	1.5
Autres	0.5
TOTAL	100.0

(c) Une entreprise souhaite étudier l'absentéisme chez ses employés pendant la saison d'hiver. Pour se faire, elle relève le nombre de jours d'absences de 50 de ses employés lors de l'hiver 2019-2020. On obtient le tableau de distribution de fréquences suivant :

Répartition de 50 employés de la compagnie selon le nombre de jours d'absence à l'hiver 2019-2020 :

Nombre de jours d'absence	Nombre d'employés	% d'employés
0	4	8.0
1	12	24.0
2	15	30.0
3	3	6.0
4	5	10.0
5	1	2.0
6	2	4.0
7	3	6.0
8 et plus	5	10.0
TOTAL	50	100.0

(d) Une entreprise souhaite étudier l'absentéisme chez ses employés pendant la saison d'hiver. Pour se faire, elle relève le nombre d'heures d'absences pour chacun de ses employés lors de l'hiver 2019-2020. On obtient le tableau de distribution de fréquences suivant :

Répartition des 50 employés de la compagnie selon le nombre d'heures d'absence à l'hiver 2019-2020 :

Nombre d'heures d'absence	Nombre d'employés	% d'employés
$[0, 5[$	10	20.0
$[5, 10[$	12	24.0
$[10, 15[$	13	26.0
$[15, 20[$	5	10.0
$[20, 25[$	6	12.0
25 et plus	4	28.0
TOTAL	50	100.0

(e) Le ministère des transports étudie les données sur les accidents qui ont eu lieu en 2019 dans un tronçon de route réputé être dangereux. Elle relève la gravité des accidents, allant de léger à mortel, de tous les accidents qui y ont eu lieu en 2019. On obtient le tableau de distribution de fréquences suivant :

Répartition des accidents selon leur gravité :

Gravité de l'accident	Nombre d'accidents	% d'accidents
Léger	90	45.0
Modéré	65	32.5
Grave	30	15.0
Mortel	15	7.5
TOTAL	200	100.0

(f) Un fabriquant de jeux vidéo souhaite connaître les habitudes de jeux de ses clients et interroge un échantillon de 50 joueurs afin de connaître le temps hebdomadaire que ces derniers passent à jouer. On obtient le tableau de distribution de fréquences suivant :

Répartition des 50 joueurs selon le temps hebdomadaire passé à jouer aux jeux vidéos :

Nombre d'heures de jeux vidéos	Nombre de clients	% de clients
$[0, 10[$	24	48.0
$[10, 20[$	10	20.0
$[20, 30[$	7	14.0
$[30, 40[$	3	6.0
$[40, 50[$	2	4.0
50 et plus	4	8.0
TOTAL	50	100.0

Réponses

1. Pour chaque mise en situation, identifiez :
   - s'il s'agit d'un recensement ou d'un sondage ;
   - la population ;
   - la taille de la population et/ou de l'échantillon ;
   - la variable ;
   - le type de variable.

   (a) On a interrogé 60 adolescents de St-Jérôme pour connaître le nombre de cigarettes qu'ils fument à chaque semaine.
   - Sondage
   - L'ensemble des adolescents de St-Jérôme
   - $n = 60$ adolescents
   - Nombre de cigarettes fumées par semaine
   - Quantitative discrète

   (b) On a interrogé 15 étudiants d'un groupe afin de savoir s'ils ont des animaux à la maison.
   - Sondage
   - L'ensemble des étudiants d'un groupe
   - $n = 15$ étudiants
   - Possession d'animaux
   - Qualitative nominale

   (c) On a interrogé les 15 étudiants d'un groupe afin de savoir combien ils ont des animaux à la maison.
   - Recensement
   - L'ensemble des étudiants d'un groupe
   - $N = 15$ étudiants
   - Nombre d'animaux
   - Quantitative discrète

   (d) On a observé le nombre de visites sur un site web pour 12 jours du mois de juin 2020.
   - Sondage
   - L'ensemble des jours du mois de juin
   - $n = 12$ jours du mois de juin
   - Nombre de visites sur un site web
   - Quantitative discrète

(e) On a pris en note la quantité de pluie tombée sur 10 villes canadiennes le 15 août dernier.

— Sondage

— L'ensemble des villes canadiennes

— $n = 10$ villes canadiennes

— Quantité de pluie tombée le 15 août dernier

— Quantitative continue

(f) On a interrogé des québécois afin de connaître leur saison préféré.

— Sondage

— L'ensemble des québécois

— $n =$?? québécois (la taille de l'échantillon n'est pas mentionnée)

— Saison préférée

— Qualitative nominale

(g) On a interrogé les étudiants habitant les résidences afin de connaître leur degré de satisfaction par rapport à la salubrité des lieux.

— Recensement

— L'ensemble des étudiants habitant les résidences

— $N =$?? étudiants (la taille de la population n'est pas mentionnée)

— Degré de satisfaction par rapport à la salubrité des résidences étudiantes

— Qualitative ordinale.

(h) On a interrogé des étudiants habitant les résidences afin de connaître le nombre d'heures de sommeil de la dernière nuit.

— Sondage

— L'ensemble des étudiants habitant les résidences

— $n =$?? étudiants (la taille de l'échantillon n'est pas mentionnée)

— Nombre d'heures de sommeil de la dernière nuit

— Quantitative continue

(i) On a pris en note le nombre de cas de COVID-19 détecté parmi les patients de 5 hôpitaux québécois pour le 5 août 2020.

— Sondage

— L'ensemble des hôpitaux québécois

— $n = 5$ hôpitaux

— Nombre de cas de COVID-19 le 5 août dernier

— Quantitative discrète

(j) On a observé le nombre d'oeufs pondus pour chacune des 10 poules d'un poulailler pendant l'hiver 2019-2020.

— Recensement

— L'ensemble des poules du poulailler

— $N = 10$ poules

— Nombre d'oeufs pondus pendant l'hiver 2019-2020

— Quantitative discrète

2. Une enseignante effectue un sondage auprès de ses étudiants. Pour chacune des questions, déterminez la variable étudiée et son type, puis présentez la série de données sous forme d'un tableau de distribution de fréquences en respectant les conventions.

(a) Variable : Degré de motivation face au cours de Probabilités et statistiques
Type : Qualitative ordinale

Répartition des 14 étudiants selon leur motivation face au cours de Probabilités et statistiques

Degré de motivation	**Nombre d'étudiants**	**% d'étudiants**
Un peu motivé.e.	4	28.6
Très motivé.e, je l'attendais depuis la session 1 !	4	28.6
J'ai pas trop le choix, c'est la dernière fois qu'il se donne.	4	28.6
Motivé !	1	7.1
À péter des règles, des calculatrices et réussir mon cours	1	7.1
TOTAL	14	100.0

(b) Variable : Nombre de cours cette session
Type : Quantitative discrète

Répartition des 15 étudiants selon le nombre de cours auxquels ils sont inscrits cette session

Nombre de cours	**Nombre d'étudiants**	**% d'étudiants**
3	1	6.7
5	9	60.0
6	4	26.7
7	1	6.7
TOTAL	15	100.0

(c) Variable : Expérience d'un cours sur Teams
Type : Qualitative nominale

Répartition des 15 étudiants selon le fait d'avoir déjà suivi un cours sur Teams ou non

Expérience de cours sur Teams	Nombre d'étudiants	% d'étudiants
Oui	9	60.0
Non	6	40.0
TOTAL	15	100.0

(d) Variable : Nombre d'animaux à la maison
Type : Quantitative discrète

Répartition des 15 étudiants selon le nombre d'animaux à la maison

Nombre d'animaux à la maison	Nombre d'étudiants	% d'étudiants
1	11	73.3
2	2	13.3
3	1	6.7
4	1	6.7
TOTAL	15	100.0

3. Une enseignante effectue un sondage auprès de ses étudiants. Pour chacune des questions, identifiez la variable et son type, puis formez des classes qui respectent les conventions.

(a) Variable : distance entre la maison et le Cégep en km
Type : quantitative continue
Pour former les classes :

— $n = 14$, donc selon la table de Sturges, le nombre de classes est d'environ 5

— Étendue = 50- 1.5 = 48.5

— Amplitude = 48.5/5 =9.7

— On choisit une amplitude de 10.

— La première classe sera $[0, 10[$, la dernière sera $[50, 60[$.

(b) Variable : Nombre d'heures par semaine de jeux vidéos
Type : quantitative continue
Pour former les classes :

— $n = 11$, donc selon la table de Sturges, le nombre de classes est d'environ 5

— Étendue = 40- 0 = 40

— Amplitude = 40/5 =8

— On choisit une amplitude de 8 ou de 10 (les deux seraient acceptées).

— La première classe sera $[0, 8[$, la dernière sera $[40, 48[$ si on prend une amplitude de 8. Si on prend une amplitude de 10, la première classe serait $[0, 10[$ et la dernière serait $[40, 50[$.

(c) Variable : Âge de l'étudiant
Type : quantitative discrète (puisque tout le monde a arrondi son âge à l'année
Même s'il s'agit d'une variable quantitative discrète, on forme des classes puisqu'il y a plus de 12 valeurs possibles.
Pour former les classes :

— $n = 20$, donc selon la table de Sturges, le nombre de classes est d'environ 5
— Étendue = 42- 19 = 23
— Amplitude = 23/5 =4.6
— On choisit une amplitude de 5.
— La première classe sera $[15, 20[$ (on choisit des bornes de classes qui sont paires ou multiples de 5), la dernière sera $[40, 45[$.

(d) Variable : Nombre préféré entre 1 et 30
Type : quantitative discrète Même s'il s'agit d'une variable quantitative discrète, on forme des classes puisqu'il y a plus de 12 valeurs possibles.
Pour former les classes :

— $n = 24$, donc selon la table de Sturges, le nombre de classes est d'environ 6
— Étendue = 30- 1 = 29
— Amplitude = $29/6 \approx 4.8$
— On choisit une amplitude de 5.
— La première classe sera $[0, 5[$ (on choisit des bornes de classes qui sont paires ou multiples de 5), la dernière sera $[30, 35[$.

4. Pour chacun des contextes suivants, identifiez s'il s'agit d'un recensement ou d'un sondage, la population, l'unité statistique, la variable étudiée, son type et le(s) nom(s) des diagramme(s) qui pourrai(en)t être utilisé(s) pour représenter la série de données obtenue.

(a) On a interrogé au hasard 1000 étudiants du Cégep de Saint-Jérôme et on leur a demandé dans quel programme ils étaient inscrits.

— Sondage
— L'ensemble des étudiants du Cégep de Saint-Jérôme
— Un étudiant du Cégep de Saint-Jérôme
— Programme d'études
— Qualitative nominale
— Diagramme circulaire ou diagramme à rectangles horizontaux

(b) On a relevé tous les décès au Québec au mois d'août 2020 et on a pris en note la cause du décès.

— Recensement

— L'ensemble des décès du mois d'août 2020 au Québec.

— Un décès qui a eu lieu en août 2020 au Québec.

— Cause du décès

— Qualitative nominale

— Diagramme circulaire ou diagramme à rectangles horizontaux

(c) Une entreprise souhaite étudier l'absentéisme chez ses employés pendant la saison d'hiver. Pour se faire, elle relève le nombre de jours d'absences de 50 de ses employés lors de l'hiver 2019-2020.

— Sondage

— L'ensemble des employés de l'entreprise à l'hiver 2019-2020.

— Un employé de l'entreprise à l'hiver 2019-2020

— Nombre de jours d'absence

— Quantitative discrète (on pourrait argumenter ici que la variable est continue, en expliquant que le nombre de jours peut être décimal)

— Diagramme en bâtons, à moins qu'il y ait plus de 12 réponses différentes. On formerait alors des classes et on utiliserait un histogramme, un polygone de fréquences ou une ogive.

(d) Une entreprise souhaite étudier l'absentéisme chez ses employés pendant la saison d'hiver. Pour se faire, elle relève le nombre d'heures d'absences pour chacun de ses employés lors de l'hiver 2019-2020.

— Recensement

— L'ensemble des employés de l'entreprise à l'hiver 2019-2020.

— Un employé de l'entreprise à l'hiver 2019-2020

— Nombre d'heures d'absence

— Quantitative continue (on pourrait argumenter ici pour dire que la variable est discrète).

— Histogramme, polygone de fréquences ou ogive.

(e) Le ministère des transports étudie les données sur les accidents qui ont eu lieu en 2019 dans un tronçon de route réputé être dangereux. Elle relève la gravité des accidents, allant de léger à mortel, de tous les accidents qui y ont eu lieu en 2019.

— Recensement

— L'ensemble des accidents en 2019 sur le tronçon étudié.

— Un accident qui a eu lieu en 2019 sur le tronçon de route étudé.

— Gravité de l'accident

— Qualitative ordinale

— Diagramme à rectangles verticaux

(f) Un fabriquant de jeux vidéo souhaite connaître les habitudes de jeux de ses clients et interroge un échantillon de 50 joueurs afin de connaître le temps hebdomadaire que ces derniers passent à jouer.

— Sondage

— L'ensemble des clients utilisant les jeux vidéos de cette compagnie.

— Un client utilisant un jeu vidéo de cette compagnie.

— Temps hebdomadaires joué par le client

— Quantitative continue (on estime que les réponses pourraient ne pas tous être des entiers)

— Histogramme, polygone de fréquences ou ogive.

5. (a) Diagramme circulaire ou diagramme à rectangles horizontaux

(b) Diagramme circulaire ou diagramme à rectangles horizontaux

(c) Diagramme en bâtons

(d) Histogramme, polygone de fréquences ou ogive.

(e) Diagramme à rectangles verticaux

(f) Histogramme, polygone de fréquences ou ogive.