Chapitre 5
Les mesures de dispersion et de position

Mesures de dispersion

Les mesures de tendance centrale que nous venons de voir permettent d'obtenir des informations au sujet d'une série statistique pour une variable **quantitative**. Par contre, comme l'illustre l'exemple suivant, deux séries statistiques différentes peuvent tout de même avoir les mêmes mesures de tendance centrale. Les mesures de tendance centrale ne sont donc pas suffisantes pour caractériser une série statistique, on a alors besoin d'autres types de mesures pour pouvoir bien les caractériser.

Exemple
Deux équipes de hockey amateurs s'affrontent dans un match amical. Voici l'âge de tous les joueurs dans chaque équipe.

Équipe 1 :	5	8	10	12	20	20	20	38	47
Équipe 2 :	18	19	20	20	20	20	20	21	22

Pour chacun des deux groupes, déterminez sa médiane et sa moyenne.

$Md_1 = 20$ ans $\quad M_1 = 20$ ans

$Md_2 = 20$ ans $\quad M_2 = 20$ ans

Bien que les mesures de tendance centrale soient les mêmes, les deux équipes sont totalement différentes. La différence concerne cependant la dispersion des données et non le centre de celles-ci. C'est là que les mesures de dispersion vont jouer un rôle.

Les mesures de dispersion permettent de caractériser l'étalement des valeurs d'une série statistique. Plus les valeurs de la série statistique seront étalées, plus la valeur de la mesure de dispersion sera élevée. Les mesures de dispersion permettront de distinguer les séries statistiques qui semblent se ressembler si on ne tient compte que des mesures de tendance centrale, comme c'est le cas dans l'exemple précédent.

Dans cette section, nous verrons trois mesures de dispersion : l'étendue, la variance et l'écart type.

L'étendue a déjà été mentionnée précédemment, lors de la description des étapes pour former des classes. Voici sa définition formelle :

L'**étendue** d'une série statistique, notée E, est définie comme étant la différence entre la valeur maximale et la valeur minimale de la série statistique.

E= valeur maximale − valeur minimale

Interprétation de l'étendue : *L'écart entre le plus grand (variable) et le plus petit (variable) est de (étendue) (unités).*

Exemple

Calculez l'étendue des deux séries statistiques données en début de chapitre.

Équipe 1 :	5	8	10	12	20	20	20	38	47
Équipe 2 :	18	19	20	20	20	20	20	21	22

on obtient $E_1 = 47 - 5 = 42$ ans et $E_2 = 22 - 18 = 4$ ans, les étendues de chacune des deux séries statistiques. Ainsi, bien que les deux séries statistiques aient les mêmes mesures de tendance centrale, elles ne sont pas étalées de la même façon. L'étendue nous indique que la première est plus étalée que la deuxième.

Dans cet exemple, on pourrait faire les interprétations suivantes :

L'écart entre l'âge le plus haut et l'âge le plus petit est de 42 ans pour l'équipe 1 et de 4 ans pour l'équipe 2.

L'étendue a le défaut de ne considérer que les deux valeurs extrêmes d'une série statistiques pour caractériser sa dispersion. Les deux prochaines mesures de dispersion, plus complexes à calculer, ont le grand avantage de considérer toutes les valeurs.

Définition

La **variance**, notée s^2 pour un échantillon ou σ^2 pour une population, est définie comme étant la moyenne des carrés des écarts par rapport à la moyenne.
La variance se calcule de la façon suivante, selon si l'étude porte sur une population ou sur un échantillon :

$$\text{Population :} \quad \sigma^2 = \frac{\sum_{i=1}^{N}(x_i - \mu)^2}{N}$$

$$\text{Échantillon :} \quad s^2 = \frac{\sum_{i=1}^{n}(x_i - \overline{x})^2}{n-1}$$

Attention : pour un échantillon, la formule est légèrement différente : on soustrait 1 au dénominateur. Tout comme pour la moyenne d'une population (μ), une lettre grecque est utilisée pour désigner la variance de la population (σ).

Interprétation de la variance : *La dispersion de (variable) des (unités statistiques) a une variance de (variance) (unités) carrées.*

En mots, ces formules signifient que pour calculer la variance, on doit, pour chacune des valeurs, faire la différence entre cette valeur et la moyenne, puis mettre ce résultat au carré. On fait ensuite la somme de ces carrés, puis on divise par la taille de la population ou par **un de moins que** la taille de l'échantillon.

Remarquez que puisque la variance est la moyenne d'une somme de **carrés**, cette dernière sera toujours positive et aura des unités mises au carré.

Reprenons l'exemple initial pour faire le calcul de la variance de chacune des séries statistiques :

Équipe 1 :	5	8	10	12	20	20	20	38	47
Équipe 2 :	18	19	20	20	20	20	20	21	22

Le contexte donné à ces deux séries permet de déduire qu'il s'agit de deux populations. On a précédemment calculé que la moyenne de la première population était de 20 ans. Afin de calculer la variance du premier groupe, il peut être aidant de faire un tableau afin d'y inscrire les calculs intermédiaires :

Âge (x_i)	Différence à la moyenne ($x_i - \mu$)	Carré de la différence à la moyenne $(x_i - \mu)^2$
5	5 - 20 = -15	225
8	8 - 20 = -12	144
10	10 - 20 = -10	100
12	12 - 20 = -8	64
20	20 - 20 = 0	0
20	20 - 20 = 0	0
20	20 - 20 = 0	0
38	38 - 20 = 18	324
47	47 - 20 = 27	729
Total		1586

Ainsi, la variance et l'intepretation de la première série est :

$$\sigma^2 = \frac{\sum_{i=1}^{N}(x_i - \mu)^2}{N}$$

$$= \frac{1586}{9}$$

$$= 176{,}22 \text{ ans}^2$$

La dispersion de l'âge des membres de l'équipe 1 a une variance de 176,22 années carrées.

Rappelons que par convention, on met 2 fois plus de chiffres après la virgule que pour la moyenne lorsque la valeur de la variance est arrondie en fin de calcul. Le calcul de la variance est long et il n'existe pas de façon directe de la calculer rapidement avec la calculatrice. Rassurez-vous, il existe tout de même une astuce. Avant de procéder au calcul de la variance du deuxième groupe, nous attendrons de voir la prochaine mesure de dispersion qui nous dévoilera l'astuce : l'écart type.

Si vous comparez la variance de deux échantillons (ou populations), vous pourrez alors affirmer que l'échantillon (ou population) avec la plus grande variance est celui qui est le plus dispersé. La variance a quelque chose d'étrange : ses unités sont carrées. Afin de remédier à cette bizarrerie, on utilise une autre mesure de dispersion, grandement inspirée par la variance : l'écart type.

Définition

L'**écart type**, noté σ pour une population ou s pour un échantillon, est défini comme la racine carrée de la variance. Il permet de mesurer la dispersion des données autour de la moyenne.
Contrairement à la variance, l'écart type a des unités *normales* (pas mises au carré). Il se calcule en effectuant une racine carrée sur la variance. On obtient donc les formules suivantes :

$$\text{Population :} \quad \sigma = \sqrt{\frac{\sum_{i=1}^{N}(x_i - \mu)^2}{N}}$$

$$\text{Échantillon :} \quad s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \overline{x})^2}{n-1}}$$

Interprétation : *En moyenne, il y a un ecart de (écart type) entre (variable) de chaque (unité statistique) et la (variable) (moyenne).*

Contrairement à la variance, l'écart type se calcule facilement à l'aide de la calculatrice. Voici la marche à suivre pour ceux qui ont un modèle Sharp.

Calcul de l'écart type avec une calculatrice Sharp

1. Entrez les données en mémoire de la même façon que pour calculer une moyenne.
2. Appuyez sur ALPHA 5 (pour un échantillon) ou ALPHA 6 (pour une population).

À l'aide de la calculatrice, on peut facilement trouver l'écart type de l'équipe 1 et celui de l'équipe 2. On obtient $\sigma_1 \approx 13.3$ ans et $\sigma_2 \approx 1.1$ ans. On peut alors faire l'interprétation suivante :
En moyenne, il y a un écart de 13.3 ans entre l'âge de chaque personne du premier groupe et l'âge moyen (20 ans), alors qu'en moyenne, il est de 1.1 ans pour chaque personne du deuxième groupe et l'âge moyen de ce dernier (20 ans).

En calculant avec la calculatrice l'écart type d'une distribution et en le mettant au carré, on peut obtenir la variance. Attention, n'arrondissez pas l'écart type avant de le mettre au carré (**les calculs sont toujours arrondis une seule fois et à la toute fin seulement**).

Dans l'exemple précédent, on obtient, en arrondissant la valeur finale à 2 décimales (double de chiffres après la virgule que la moyenne) : la variance du groupe 1 est de $\sigma_1^2 \approx 176.22$ ans^2 et celle du groupe 2 est de $\sigma_2^2 \approx 1.11$ ans^2. On peut alors affirmer que les données du premier groupe sont plus dispersées que celles du deuxième groupe.

Exercice
Voici le temps utilisé par un échantillon de 10 ordinateurs d'une entreprise pour l'exécution d'un même programme (en dixièmes de seconde) :

4.3 3.6 3.6 3.3 4.8 4.5 6.1 5.2 5.4 5.1

Calculer l'étendue, la variance et l'écart-type et donner leur interprétation.

E = 6,1 - 3,3 = 2,8 dixièmes de secondes.

Il y a un écart de 2,8 dixièmes de seconde entre l'ordinateur qui exécute le programme le plus rapidement et celui qui le fait le plus lentement.

$s^2 = 0,8143$ (dixièmes de secondes)^2

La dispersion des temps d'exécution d'un programme des 10 ordinateurs d'une entreprise est de 0,8143 dixièmes de secondes au carrées.

S = 0,90 dixièmes de secondes

En moyenne, il ya un écart de 0,90 dixièmes de secondes entre le temps d'exécution d'un programme de chaque ordinateur et le temps d'exécution moyen (4,59 dixièmes de secondes).

Données présentées dans un tableau de distribution sans classe.

Nous allons maintenant voir comment se calculent les trois mesures de dispersion présentées dans la section précédente si les données sont présentées dans un tableau de distribution de fréquences **sans** classe.

Définition

Le calcul de l'étendue se fait de la même façon que lorsque les données sont présentées sans tableau :

$$E = \text{Valeur max} - \text{Valeur min}$$

Les formules pour l'écart type sont :

$$\text{Population :} \quad \sigma = \sqrt{\frac{\sum(x_i - \mu)^2 \cdot n_i}{N}}$$

$$\text{Échantillon :} \quad s = \sqrt{\frac{\sum(x_i - \overline{x})^2 \cdot n_i}{n-1}}.$$

Étape sur la calculatrice modèle SHARP :

1. Vider la mémoire avant d'entrer de nouvelles données : 2e fonction Mode (CA)
2. Entrer la 1ère donnée, suivie de la touche sto, entrer la fréquence et appuyer sur M+. Faire cela jusqu'à la fin de toutes les données.
3. On appuie sur ALPHA 5 (sx) si c'est un échantillon ou ALPHA 6 (σx) si c'est une population.

La différence entre ces formules et celles pour les données qui ne sont pas présentées dans un tableau, c'est tout simplement que plutôt que d'additionner un certain nombre (n_i) de fois la même valeur ($(x_i - \mu)^2$ ou $(x_i - \overline{x})^2$), on va multiplier cette valeur ($(x_i - \mu)^2$ ou $(x_i - \overline{x})^2$) par le nombre de fois (n_i) qu'elle apparaîtrait dans la somme.

Exemple

Calculer l'étendue, l'écart-type et la variance et donner les interprétations des données présentées dans le tableau à la page suivante. Notez qu'on arrondit la variance avec le double de décimales qu'en a l'écart type et la moyenne, donc ici, à 2. Dans cet exemple, puisque les 101 employés sont une partie de l'ensemble de tous les employés de la compagnie, il s'agit d'un échantillon. L'écart type sera donc noté s et on utilisera alors la deuxième formule pour effectuer le calcul.

Répartition de 101 employés de la compagnie selon le nombre de jours d'absence à l'hiver 2019-2020

Nombre de jours d'absence	Nombre d'employés	% d'employés
0	10	9.9
1	12	11.9
2	35	34.7
3	28	27.7
4	10	9.9
5	3	3.0
6	1	1.0
7	1	1.0
8 et plus	1	1.0
TOTAL	101	100.0

$E = 8 - 0 = 8$ jours

$s = 1{,}4$ jours

$s^2 = 2{,}08$ jours^2

- Il y a un écart de 8 jours d'absence entre l'employé qui en prend le plus et celui qui en prend le moins à l'hiver 2019-2020.
- En moyenne, il y a un écart de 1,4 jour d'absente entre le nombre de jours d'absence d'un employé et le nombre de jours d'absence moyen (2,4 jours) à l'hiver 2019-2020.
- La dispersion des jours d'absences à l'hiver 2019-2020 des 101 employés d'une compagnie a une variance de 2,08 jours d'absence carrés.

Données présentées dans un tableau de distribution avec classes

Puisque les données sont groupées par classe, on ne connaît pas les valeurs des données brutes. Tout comme pour les mesures de tendance centrale présentées dans un tableau avec classes, les mesures de dispersion que nous calculerons ne sont que des estimations des vraies valeurs. Dans les interprétations de ces mesures, on retrouvera donc le mot **environ** pour signifier qu'il s'agit d'approximations.

Définition

Pour des données groupées en classe, l'**étendue** est définie comme suit :

E ≈ Borne supérieure de la dernière classe - Borne inférieure de la première classe.

Remarquons que puisque la dernière classe est ouverte, on suppose que son amplitude est la même que les autres classes afin de faire les calculs.

Définition

Tout comme pour le calcul de la moyenne avec des données regroupées par classe, l'approximation de l'écart type se fera en utilisant le point milieu de chacun des intervalles. Ainsi, on obtient les formules pour l'écart type pour les données groupées par classe en remplaçant les x_i des formules de la section précédente par des m_i :

$$\text{Population :} \quad \sigma \approx \sqrt{\frac{\sum(m_i - \mu)^2 \cdot n_i}{N}}$$

$$\text{Échantillon :} \quad s \approx \sqrt{\frac{\sum(m_i - \overline{x})^2 \cdot n_i}{n-1}}.$$

Le calcul avec la calculatrice se fait en entrant les points milieu des classes et la fréquence absolue des classes correspondantes.

Exemple

Calculer l'étendue, l'écart-type et la variance et donner les interprétations des données présentées dans le tableau .

Distribution de 60 employés choisis au hasard selon le nombre d'heures d'absence pendant l'hiver 2019-2020

	Nombre d'heures d'absence	Nombre d'employés	Pourcentage d'employés(%)
2,5	[0; 5[	10	16.7
7,5	[5; 10[	24	40.0
12,5	[10; 15[	7	11.7
17,5	[15; 20[	10	16.7
22,5	20 et plus	9	15.0
	Total	60	100.0

$E = 25 - 0 \approx 25$ heures d'absence

$s \approx 6,7$ heures d'absence

$s^2 \approx 44,80$ (heures d'absence)^2

• Il y a un écart d'environ 25 h d'absence entre l'employé le plus absent et l'employé le moins absent à l'hiver 2019 - 2020.

• En moyenne, il y a un écart d'environ 6,7 heures d'absence entre le nombre d'heures d'absence d'un employé et le nombre d'heures d'absence moyen (11,2 heures) à l'hiver 2019-2020.

• La dispersion des heures d'absences à l'hiver 2019-2020 de 60 employés a une variance d'environ 44,80 heures d'absence carrées.

Exercice

Calculer l'étendue, l'écart-type et la variance et donner les interprétations des données présentées dans le tableau.

Répartition de 39 blocs d'alimentation selon leur poids en grammes

	Poids (g)	Nombre de blocs d'alimentation	Pourcentage de blocs d'alimentation (%)
256,5	[255, 258[	1	2,6
259,5	[258, 261[	4	10,3
262,5	[261, 264[	11	28,2
265,5	[264, 267[	15	38,5
268,5	[267, 270[	6	15,4
271,5	[270, 273[	2	5,1
	Total	39	100

- L'écart entre le bloc d'alimentation le plus lourd et le bloc d'alimentation le plus léger est d'environ 18g.

$E = 273 - 255 \approx 18g$

$s \approx 3,3g$

$s^2 \approx 10,97g^2$

- En moyenne, il y a un écart d'environ 3,3g entre le poids d'un bloc d'alimentation et le poids moyen des blocs (264,6g).
- La dispersion des poids des blocs d'alimentation a une variance d'environ $10,97g^2$.

Mesure de position : cote Z

Dans cette section, nous présenterons la cote Z, une mesure de position. Tout comme pour les autres mesures, elle ne s'applique qu'aux variables quantitatives. C'est cette mesure qui se cache derrière le calcul de la cote R et qui permet de situer une donnée par rapport aux autres données d'une série statistique. Notez qu'il n'y aura qu'une seule façon de calculer cette mesure, peu importe de quelle façon les données sont présentées.

Supposons qu'une enseignante enseigne le même cours à deux groupes, disons le groupe 101 et le groupe 102. Pierre est dans le groupe 101 et a eu une note de 75% à l'examen, alors que Jean, dans le groupe 102, a eu 85%. Est-ce que Jean est effectivement meilleur que Pierre ?

Afin d'être en mesure de comparer Pierre et Jean, on a besoin de plus d'informations. L'examen était-il de même diffficulté dans les deux groupes ? Est-ce que l'enseignante a corrigé de la même façon les examens ? Peut-être a-t-elle été plus sévère lors de la correction de son premier groupe ? La cote Z pourra nous aider à comparer les performances de Pierre et de Jean.

Définition

La **cote** Z, notée Z, est une mesure de position d'une valeur par rapport à la moyenne de l'ensemble des valeurs. Cette mesure donne la distance entre une donnée et la moyenne de l'ensemble des données en nombre d'écarts types.
Les formules de la cote Z sont les suivantes :

$$Z = \frac{x - \overline{x}}{s} \quad \text{pour un échantillon}$$

ou

$$Z = \frac{x - \mu}{\sigma} \quad \text{pour une population.}$$

Une cote Z varie généralement entre -3 et 3 et le signe de cette dernière peut être interprété comme suit :

- $Z > 0$: la valeur se situe au-dessus de la moyenne ;
- $Z = 0$: la valeur est égale à la moyenne ;
- $Z < 0$: la valeur se situe au-dessous de la moyenne.

Interprétation : La valeur (valeur) se situe à (cote Z en valeur absolue) écarts types (au-dessus ou sous) la moyenne.

Exemple

Ainsi, la cote Z nous permettra de comparer les résultats de Pierre et Jean en mesurant l'écart à la moyenne en nombre d'écarts types.
Dans notre exemple, supposons que la moyenne et l'écart type du premier groupe soient respectivement de $\mu_1 = 70$ et $\sigma_1 = 2.5$ et que ceux du deuxième groupe soient respectivement de $\mu_2 = 80$ et $\sigma_2 = 10$. Calculons les cotes Z de Pierre et de Jean :

$$\begin{aligned} Z_P &= \frac{75 - 70}{2.5} \\ &= \frac{5}{2.5} \\ &= 2 \end{aligned}$$

et

$$\begin{aligned} Z_J &= \frac{85 - 80}{10} \\ &= \frac{5}{10} \\ &= 0.5 \end{aligned}$$

Cela signifie que Pierre a réussi à avoir une note qui se situe à 2 écarts types au-dessus de la moyenne de sa classe alors que Jean n'est qu'à un demi écart type au-dessus de la moyenne. On va donc considérer que Pierre a mieux réussi son examen malgré que sa note soit inférieure à celle de Jean.

Exercice

Calculer et interpréter la cote Z de Louis qui fait partie du groupe 102 et qui a eu une note de 75%.

$\mu = 80\%$

$$Z_L = \frac{75-80}{10}$$

$$= -0{,}5$$

La note de Louis (75%) se situe à 0,5 écart-type sous la moyenne du groupe.

Exemple

Jacques a fait un examen pour lequel la moyenne du groupe était de 80% et l'écart type était de 10%. Si Jacques a une cote Z de 1.25, quelle note a-t-il obtenu à l'examen ?

On sait que $\mu = 80\%$, que $\sigma = 10\%$ et que $Z = 1.25$. On doit donc résoudre l'équation suivante :

$$\begin{aligned} Z &= \frac{x-\mu}{\sigma} \\ 1.25 &= \frac{x-80}{10} \\ 12.5 &= x-80 \\ 12.5+80 &= x \\ x &= 92.5 \end{aligned}$$

Ainsi, Jacques a réussi son examen avec une note de 92.5 %.

Exercice

On étudie le poids (en grammes) de 28 pièces électroniques produites par une machine. Si le poids moyen est de 14,2 g et l'écart type de 3 g, quelle est le poids d'une pièce ayant une cote Z de -1.5 ?

$\bar{x} = 14{,}2\,g$

$s = 3$

$x = ?$

$Z = -1{,}5$

$$Z = \frac{x-\bar{x}}{s}$$

$$-1{,}5 = \frac{x-14{,}2}{3}$$

$$-4{,}5 = x-14{,}2$$

$$9{,}7\,g = x$$

Données présentées dans un tableau

Le fait que les données soient présentées dans un tableau sans classe n'a aucun impact sur la façon de calculer la cote Z. La cote Z d'une donnée qui a la valeur x est :

$$Z = \frac{x - \overline{x}}{s} \quad \text{s'il s'agit d'un échantillon}$$

$$Z = \frac{x - \mu}{\sigma} \quad \text{s'il s'agit d'une population}$$

Si les données sont groupées en classe et que la moyenne et l'écart type sont des approximations, on ajoutera le mot **environ** à l'interprétation et on utilisera le symbole $\approx$ plutôt que $=$ dans les calculs.

Exercice

Calculer la cote Z et donner l'interprétation pour un bloc d'alimentation ayant un poid de 265g .

Répartition de 39 blocs d'alimentation selon leur poids en grammes

Poids (g)	Nombre de blocs d'alimentation	Pourcentage de blocs d'alimentation (%)
[255, 258[	1	2,6
[258, 261[	4	10,3
[261, 264[	11	28,2
[264, 267[	15	38,5
[267, 270[	6	15,4
[270, 273[	2	5,1
Total	39	100

$\overline{X} \approx 264,6g$

$s \approx 3,3g$

$Z \approx \frac{265 - 264,6}{3,3}$

$\approx 0,13$

Le bloc d'alimentation a un poids qui se situe à envion 0,13 écart-type au-dessus de la moyenne.

Cote R (à titre informatif)

Jusqu'en 1977, les étudiants étaient admis à l'université sur la base de leurs notes. En 1977, la cote Z a commencé à être utilisée afin de compenser pour des évaluations qui pouvaient être de différentes difficultés d'un cégep à l'autre (influençant alors la moyenne) et corrigées plus ou moins sévèrement (un enseignant qui corrige sévèrement aura un plus grand écart type dans ses évaluations qu'un enseignant corrigeant moins sévèrement).

Bien que la cote Z semblait rectifier certaines inéquités, il en restait encore à corriger. Entre autres, un étudiant qui était dans un groupe fort avait plus de difficulté a obtenir une note bien au-dessus de la moyenne que s'il avait été dans un groupe faible. C'est donc pour corriger ce genre d'inéquité que la cote R a été introduite en 1994. Depuis, elle a subi quelques modifications afin de corriger des irrégularités, la dernière datant de 2017. Pour chacun des cours d'un étudiant, une cote R est calculée comme suit (sauf à l'hiver 2020) et on fait ensuite une moyenne pondérée des cotes R selon le poids des cours dans le programme de l'étudiant :

$$R = ((Z \cdot \text{IDGZ} + \text{IFGZ} + 5) \cdot 5,$$

où :

— Z est la cote Z dans le cours ;

— IDGZ est une mesure qui tient compte de l'homogénéité ou pas des étudiants composant le groupe ;

— IFGZ est une mesure qui tient compte de la force des étudiants composant le groupe ;

— le +5 et le x 5 sont ajoutées pour obtenir une cote R positive et située entre 0 et 50.

La multiplication par l'IDGZ vient compenser le fait qu'il est difficile de se démarquer dans un groupe d'étudiant de force semblable, alors que l'addition de l'IFGZ vient compenser pour le fait qu'il est difficile de se démarquer dans un groupe fort. Ces deux mesures (IDGZ et IFGZ) sont calculées à partir de certaines notes du secondaire des étudiants qui forment le groupe.

Avantages et inconvénients des différentes mesures

Pour terminer ce chapitre, voyons les avantages et inconvénients des différentes mesures statistiques.

La médiane

Avantages :

- Elle donne le centre de la distribution.
- Elle ne dépend pas de la valeur des données, mais de leur position.
- Dans le cas des données regroupées en classes, elle est peu influencée par le choix des classes.